Previsão de casos e mortalidade de COVID-19 utilizando técnicas de Big Data e Machine Learning

Luís Coimbra
Instituto Politécnico de Coimbra,
Coimbra Business School, ISCAC,
Coimbra, Portugal
iscac17458@alumni.iscac.pt

Abstract — **O objetivo deste trabalho consiste em utilizar técnicas de Big Data para realizar previsões de casos e mortalidade relacionados ao vírus do COVID-19. No entanto, além da previsão, será dado um importante foco à análise descritiva dos dados do dataset. Serão examinados pontos essenciais como a taxa de sobrevivência nos diferentes países, fatores que possam ter impacto na transmissão do vírus e quais destes países foram mais, ou menos afetados pelo vírus (irá também ser analisado o país Portugal). Para realizar esta análise, foi utilizado um conjunto de dados "COVID19 Global Forecasting (Week 3)", disponível no Kaggle. Essa análise exploratória será fundamental para entender a evolução da pandemia em diferentes regiões do mundo e para orientar a criação de modelos preditivos mais precisos. Dado isto, ainda que o pico da influência do COVID-19 demonstre já ter passado, espero contribuir para o desenvolvimento de estratégias mais eficazes de prevenção e controlo do vírus.**

Keywords – COVID-19; Big Data; Machine-Learning; Previsão; Casos confirmados; Mortalidade; Análise descritiva; Dataset; Transmissão do vírus; Modelos preditivos.

I. INTRODUÇÃO

A pandemia do COVID-19 tem sido um dos maiores desafios enfrentados pela sociedade nos últimos tempos. A rápida transmissão e a alta taxa de mortalidade associada tornam esta doença uma ameaça global. Neste contexto, a utilização de técnicas de Big Data e Machine Learning podem consistir em ferramentas valiosas com o propósito de prever os casos e a mortalidade em diferentes países. Isto com o objetivo de adquirir informação e adotar medidas adequadas à situação de cada país. A análise de um grande conjunto de dados com informações epidemiológicas pode ajudar a entender a evolução da doença e a identificar fatores de risco e vulnerabilidade. Além disso, a criação de modelos preditivos precisos pode ser útil para orientar a tomada de decisão em saúde pública e para o planeamento de medidas preventivas e de controle da pandemia.

II. COVID-19 – O INÍCIO

O primeiro caso de COVID-19 foi identificado em Wuhan, China no dia 31 de dezembro de 2019, sendo que se espalhou rapidamente por todo o Mundo.

A WHO (World Health Organization) declarou este vírus como uma emergência mundial, pouco depois do seu surgimento, no dia 30 de janeiro de 2020.

Um surto de uma doença infeciosa é uma ocorrência que normalmente não é esperada numa determinada comunidade ou região geográfica. Esta implica em si, uma rápida propagação do vírus, pondo em perigo a saúde de uma grande porção da população, pelo que exige uma ação imediata de modo a prevenir a doença a nível comunitário. Neste caso, foram adotados por vários países várias medidas para combater a sua propagação tais como:

1. **Restrições de viagens**: muitos países impuseram restrições de viagens de modo a limitar a propagação do vírus entre países e regiões;
2. **Distanciamento Social**: encerramento de escolas e universidades; limitação do tamanho de eventos e reuniões; incentivos para as pessoas trabalharem de casa;
3. **Uso de máscaras**: Utilização de máscaras em locais públicos para limitar a propagação do vírus;
4. **Testagem:** muitos países aumentaram a testagem para identificar casos de COVID-19;
5. **Vacinação:** implementação de programas de vacinação com objetivo de proteger as pessoas contra o vírus.

Em termos dos sintomas gerados de infeção estes incluem: febre, tosse, falta de ar e diarreia. Em casos mais graves, o vírus pode causar pneumonia e até morte.

III. INFLUÊNCIA MUNDIAL

Tal como foi dito anteriormente o COVID-19 veio a afetar o comportamento de toda a população mundial. A pandemia provocou "lockdowns" e medidas de restrição que vieram a afetar os setores económicos, turísticos e ambientais. Para além disto, este vírus veio a ter determinado efeito sobre a saúde mental de uma grande porção da população que vieram a ter pela primeira vez em muitos anos uma restrição da sua liberdade.

1. Económico

A pandemia veio ter um impacto significativo sobre a economia, afetando negativamente muitos setores e indústrias. As medidas de restrição e distanciamento social levaram ao encerramento de muitos negócios, traduzindo-se então numa redução de produção e emprego. Para além disto, as interrupções nas cadeias de produção e os aumentos dos custos de transporte vieram a afetar o comércio internacional.

De modo a combater estes efeitos, muitos governos adotaram medidas de estímulo económico, incluindo empréstimos, subsídios e transferências diretas de dinheiro, a fim de mitigar os impactos económicos negativos.

2. Impacto Mental

A pandemia veio também ter grande impacto sobre a saúde mental das pessoas em todo o mundo. O isolamento social, a incerteza económica e as preocupações com a saúde pessoal aumentaram a ansiedade e o stress diário. Além disto, o aumento da exposição às notícias sobre a pandemia, muitas vezes sensacionalistas, pode levar a aumento da depressão e do medo.

Quanto à população mais jovem, o encerramento das escolas e universidades levaram à fraca socialização entre os mesmos, o que gerou grandes níveis de depressão.

3. Turístico

Quanto à indústria do turismo, as restrições de viagens, quarentenas obrigatórias e encerramento de fronteiras levaram a uma queda do número de viagens realizadas, traduzindo-se então em perdas financeiras significativas.

4. Ambiental

Uma das poucas consequências positivas do COVID-19 foi a diminuição da poluição e dos impactos ambientais causados pela atividade humana.

Com as restrições de viagens e diminuição de atividade económica, houve uma redução significativa na emissão de poluentes atmosféricos, como o dióxido de carbono, óxido de nitrogénio e dióxido de enxofre (poluentes derivados de queima de combustíveis).

5. Religião

As medidas de restrição e distanciamento social afetaram diretamente as atividades religiosas, como missas, cultos, peregrinações e outros eventos. Muitas igrejas, templos, mesquitas e sinagogas tiveram que fecham temporariamente, limitar a capacidade de público ou realizar cerimónias online.

IV. INFLUÊNCIA EM PORTUGAL

Desde o início do período pandémico, Portugal enfrentou pelo menos, cinco importantes vagas da doença, que resultaram num aumento do número de mortes esperados pela pré-pandemia (gráfico 1).

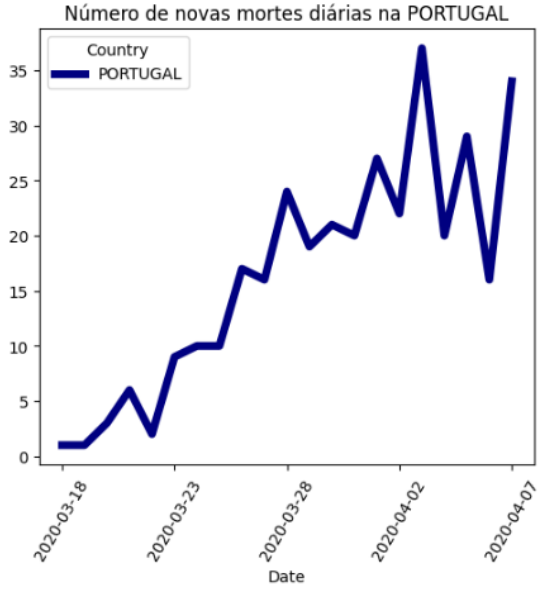


Figura 1- Número de novas mortes em Portugal Fonte: Elaboração própria no Colab.

Do ponto de vista económico, a pandemia resultou em perdas imediatas do produto interno bruto (PIB), com cerca de uma queda de 150 mil empregos para o segundo trimestre de 2020, 1,5 milhões de pessoas em regime de "layoff" e cerca de um quarto da força de trabalho por conta de outrem com salários apoiados por medidas implementadas pelo governo.

Tendo em conta a especialização produtiva de Portugal, este demonstrou ser especialmente vulnerável a crises pandémicas. No entanto, Portugal demonstrou ser capaz de recuperar rapidamente após o segundo período de confinamento, sendo esta recuperação provocada por dois sucessos:

1. **Aquisição e distribuição de vacinas** de elevada eficácia;
2. **Criação de uma estrutura centralizada de vacinação** capaz de vacinar 85% da população em cerca de 10 meses.

Estas medidas vieram a ter grande efeito sobre a economia que veio a ter uma recuperação significativa face aos valores pré-pandémicos.

A pandemia teve também um impacto significativo na sociedade portuguesa. As medidas de distanciamento social e o isolamento levaram a um aumento da solidão, especialmente entre idosos e pessoas vulneráveis, sendo que o encerramento de escolas e universidades e a transição para o ensino à distância, levaram a que muitos estudantes adquirissem níveis de depressão.

V. METODOLOGIA

O presente trabalho tem como objetivo realizar, utilizando o colab, uma previsão de casos e mortes derivados do vírus Covid-19 entre 22 de janeiro e 7 de abril por região. O objetivo principal passa também por identificar alguns fatores que vão ter impacto na transmissão deste vírus entre a população escolhida.
Para tal é utilizado um dataset da Kaggle : "COVID19 Global Forecasting (Week 3)", que apresenta 2 datasets , um treino com objetivo de treinar os dados e um de teste para aplicar os métodos escolhidos.
Foi realizada uma análise descritiva dos dados utilizando pandas e PySpark , do qual serão aplicados alguns métodos de previsão como : Naive ; Seasonal Naive ; AutoARIMA; Previsão com Regressão Linear; Previsão com Random Forest; Previsão com Decision Tree.
É importante mencionar que os resultados obtidos com os últimos 3 não foram corretamente obtidos logo irá ser dado um principal foco na previsão Naive,Seasonal Naive, e AutoARIMA.
A escolha destes métodos passa pela sua familiaridade em outra cadeira do Mestrado do qual estes são aplicados, também, a datasets temporais.

VI. ANÁLISE EXPLORATÓRIA DOS DADOS

Nesta parte do artigo irão ser analisados alguns dos pontos essenciais para a interpretação do dataset escolhido.

1) Dataset de treino

Através de comandos disponíveis do PySpark, é demonstrado de seguida o dataset próprio para o treino dos dados. (figura2)

Id	Province_State	Country_Region	Date	ConfirmedCases	Fatalities
1	null	Afghanistan	2020-01-22	0.0	0.0
2	null	Afghanistan	2020-01-23	0.0	0.0
3	null	Afghanistan	2020-01-24	0.0	0.0
4	null	Afghanistan	2020-01-25	0.0	0.0
5	null	Afghanistan	2020-01-26	0.0	0.0
6	null	Afghanistan	2020-01-27	0.0	0.0
7	null	Afghanistan	2020-01-28	0.0	0.0
8	null	Afghanistan	2020-01-29	0.0	0.0
9	null	Afghanistan	2020-01-30	0.0	0.0
10	null	Afghanistan	2020-01-31	0.0	0.0
11	null	Afghanistan	2020-02-01	0.0	0.0
12	null	Afghanistan	2020-02-02	0.0	0.0
13	null	Afghanistan	2020-02-03	0.0	0.0
14	null	Afghanistan	2020-02-04	0.0	0.0
15	null	Afghanistan	2020-02-05	0.0	0.0
16	null	Afghanistan	2020-02-06	0.0	0.0
17	null	Afghanistan	2020-02-07	0.0	0.0
18	null	Afghanistan	2020-02-08	0.0	0.0
19	null	Afghanistan	2020-02-09	0.0	0.0
20	null	Afghanistan	2020-02-10	0.0	0.0

only showing top 20 rows

Figura 2- Dataset treino

```
root
 |-- Id: string (nullable = true)
 |-- Province_State: string (nullable = true)
 |-- Country_Region: string (nullable = true)
 |-- Date: string (nullable = true)
 |-- ConfirmedCases: string (nullable = true)
 |-- Fatalities: string (nullable = true)
```

Figura 3 - Schema do dataset treino

Como é possível analisar, o dataset disponibiliza-nos com 6 colunas:

- **ID** – identificação do caso
- **Province-State** – subdivisão administrativa do país
- **Country_Region** – Região do país
- **Date** – Data do caso (22 de janeiro a 7 de abril de 2020)
- **ConfirmedCases** – Número de casos confirmados
- **Fatalities** – Número de mortes

summary	Id	Province_State	Country_Region	Date	ConfirmedCases	Fatalities
count	23562	10010	23562	23562	23562	23562
mean	16356.5	null	null	null	801.3232747644512	37.46761734997029
stddev	9451.977497328919	null	null	null	6312.495887595646	468.6993367629121
min	1	Alabama	Afghanistan	2020-01-22	0.0	0.0
max	9999	Zhejiang	Zimbabwe	2020-04-07	9976.0	99.0

Figura 4- Descrição do dataset treino

Através da descrição do dataset podemos analisar que a coluna "Province_State" apresenta valores Null , o que para uma maior facilidade de compreensão , este foi retirado.

2) Dataset de teste

ForecastId	Province_State	Country_Region	Date
1	null	Afghanistan	2020-03-26
2	null	Afghanistan	2020-03-27
3	null	Afghanistan	2020-03-28
4	null	Afghanistan	2020-03-29
5	null	Afghanistan	2020-03-30
6	null	Afghanistan	2020-03-31
7	null	Afghanistan	2020-04-01
8	null	Afghanistan	2020-04-02
9	null	Afghanistan	2020-04-03
10	null	Afghanistan	2020-04-04
11	null	Afghanistan	2020-04-05
12	null	Afghanistan	2020-04-06
13	null	Afghanistan	2020-04-07
14	null	Afghanistan	2020-04-08
15	null	Afghanistan	2020-04-09
16	null	Afghanistan	2020-04-10
17	null	Afghanistan	2020-04-11
18	null	Afghanistan	2020-04-12
19	null	Afghanistan	2020-04-13
20	null	Afghanistan	2020-04-14

only showing top 20 rows

Figura 5- Dataset de teste

Tal como no dataset treino, o Province_State irá ser removido para uma maior facilidade de compreensão.
Já este dataset de teste apresenta 4 colunas:

- **ForecastID –** identificação do caso previsto
- **Province_State –** subdivisão administrativa do país
- **Country_Region -** Região do país

- **Date –** Data do caso previsto

```
root
 |-- ForecastId: string (nullable = true)
 |-- Province_State: string (nullable = true)
 |-- Country_Region: string (nullable = true)
 |-- Date: string (nullable = true)
```

Figura 6 - Schema do dataset teste

summary	ForecastId	Province_State	Country_Region	Date
count	13158	5590	13158	13158
mean	6579.5	null	null	null
stddev	3798.531755823558	null	null	null
min	1	Alabama	Afghanistan	2020-03-26
max	9999	Zhejiang	Zimbabwe	2020-05-07

Figura 7 - Descrição do dataset teste

3) Número de países e dias

Com recurso a comandos disponíveis do PySpark podemos verificar que o dataset treino apresenta 180 países e 77 dias, e o dataset teste 180 países e 43 días.

4) Top 10 países com mais casos e mortalidade

Country_Region	ConfirmedCases
China	4764627.0
US	3222547.0
Italy	2078445.0
Spain	1614510.0
Germany	1249835.0
France	987338.0
Iran	915866.0
United Kingdom	467602.0
Korea, South	328015.0
Switzerland	296853.0

Figura 8 - Top 10 países com mais casos confirmados

Como é possível analisar pela figura anterior, o país que apresenta um maior número de casos confirmados corresponde à China (país de origem do COVID-19).

Country_Region	Fatalities
Italy	223179.0
China	169091.0
Spain	137486.0
US	77343.0
France	72246.0
Iran	58527.0
United Kingdom	38835.0
Netherlands	17252.0
Germany	14032.0
Belgium	12524.0

Figura 9 - Top 10 países com maior mortalidade

Como é possível interpretar, a Itália corresponde ao país com uma maior mortalidade com cerca de 223179 mortes totais entre o período determinado (22 de janeiro a 7 de abril de 2020)

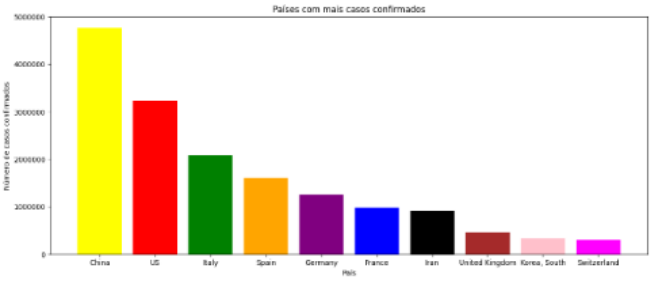


Figura 10 - Top 10 países com mais casos em gráfico de tabelas

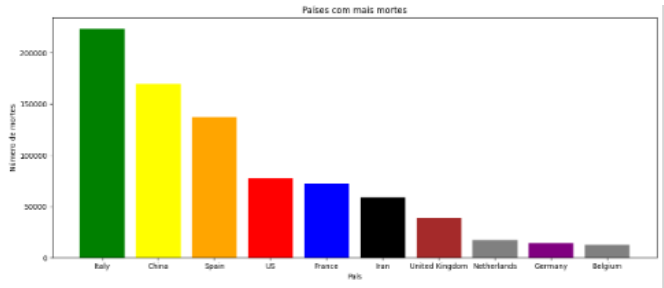


Figura 11 - Top 10 países com maior mortalidade em gráfico de tabela

Com a interpretação dos gráficos anterior podemos verificar que:

1) A China aparenta ser o país com um maior número de casos confirmados. No entanto, não corresponde ao país com maior mortalidade pois este lugar pertence à Itália.
2) Países como Netherlands e Belgium não estão representados nos 10 países com mais casos confirmados. No entanto, estão situados respetivamente na posição 8º e 10º dos países com maior mortalidade.

Como é possível analisar o país italiano aparenta ter uma % muito elevada de mortalidade, sendo que cerca de uma em cada 10 pessoas morre do vírus do COVID.
Esta alta taxa de mortalidade pelo COVID-19 pode ser explicada por vários fatores como:

1 - **Idade da população** - A Itália tem uma das populações mais antigas do mundo, com uma alta proporção de pessoas com mais de 65 anos, que são consideradas um grupo de alto risco para a COVID-19;

2 - **A rápida propagação do vírus;**

3 - **Capacidade limitada do sistema de saúde** - A Itália tem um sistema de saúde publico com recursos limitados e que foi rapidamente sobrecarregada pela pandemia;

4 - **Falta de testes de covid** - o que gerou uma grande dificuldade da identificação dos casos.

5) Evolução da tendência de crescimento do número de casos e mortes nos 2 países com maior Mortalidade (China, Itália) e interpretação de Portugal

A) China

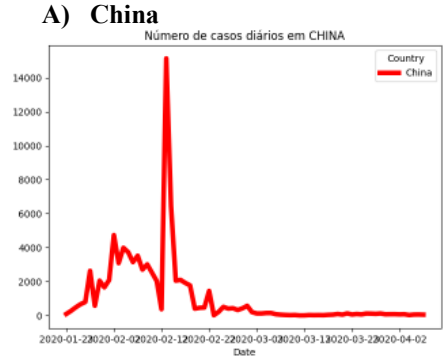


Figura 12 - Número de Casos diários na China



Figura 13- Número de mortes diárias na China

Em termos de casos a China apresenta um pico extremo no dia 12-02-2020. No entanto aparenta ser dos países que apresenta um maior nível de controlo de casos, que pode ser explicado de duas maneiras: Ou ocorreu um controlo extremo da população de modo a impedir a propagação do covid, ou ocorreu um declínio de testes de covid.
O número de mortes apresenta também um grande controlo apresentando um grande decrescimento no dia 23-02-2020.

B) Itália

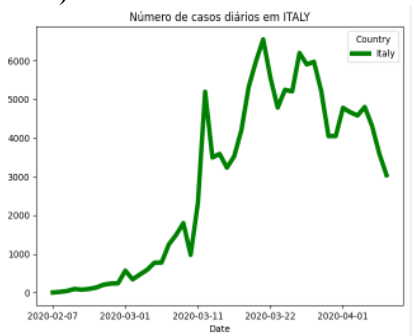


Figura 14 - Número de casos diários na Itália

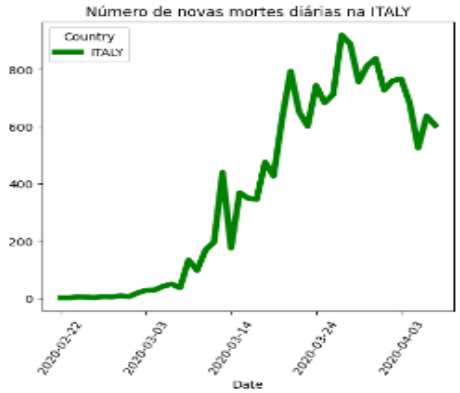


Figura 15 - Número de mortes diárias na Itália

Com a interpretação do gráfico de número de novas mortes na Itália podemos compreender os fatores explicados anteriormente, uma vez que apresentam uma grande tendência para subir o número de mortes, sendo que a meio de março começam a ter um decrescimento.

C) Portugal

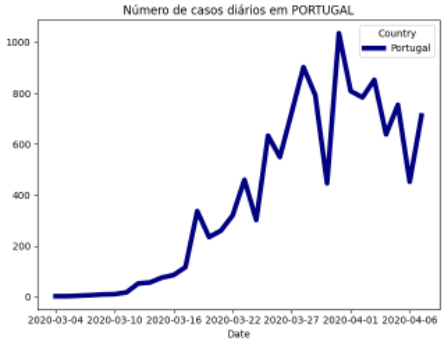


Figura 16 - Número de casos diários em Portugal

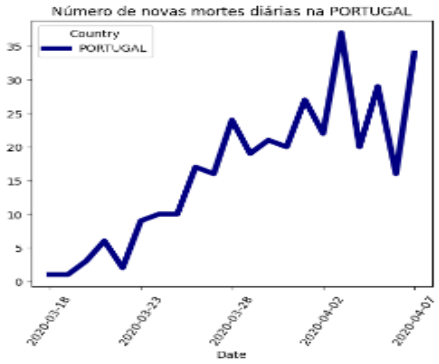


Figura 17 - Número de mortes diárias em Portugal

Quanto a Portugal podemos analisar que o número de casos e mortes apresentam uma constate subida e descida de valores sendo que com a análise podemos perceber que existe a partir do dia 02-04-2020 uma certa tendência para o decrescimento do número de casos.

VII. APRESENTAÇÃO DOS RESULTADOS PREVISTOS

Dado que os países interpretados anteriormente foram a China, Itália e Portugal, de seguida seguem alguns dos resultados previstos para estes países utilizando os métodos Naive, SeasonalNaive e autoARIMA.

O modelo **"Naive"** assume que a série temporal irá manter o valor do período anterior como a previsão para o período seguinte.
Já o modelo **"Seasonal Naive"** é uma variação do modelo "Naive" que considera a sazonalidade na série temporal. Ele assume que a previsão para o próximo período será o mesmo valor que o período anterior no mesmo ponto da sazonalidade.
O **"AutoARIMA"** é um modelo estatístico usado para prever valores futuros de uma variável com base nos seus valores passados. Ele automatiza a escolha dos valores dos parâmetros do modelo ARIMA, que é composto por três partes: AR para relação entre valores passados e atuais, MA para relação entre erros passados e atuais, e I para modelar a tendência dos dados tornando a série estacionária.

China

	index	unique_id	ds	Naive	SeasonalNaive	autoARIMA
3240	3240	China	2020-04-08	1265.0	138.0	403.240143
3241	3241	China	2020-04-09	1265.0	560.0	-314.011078
3242	3242	China	2020-04-10	1265.0	180.0	562.234619
3243	3243	China	2020-04-11	1265.0	1.0	954.544250
3244	3244	China	2020-04-12	1265.0	76.0	540.439331

Figura 18 - Previsão do número de casos para a China

China

	unique_id	ds	Naive	SeasonalNaive	autoARIMA
3240	China	2020-04-08	1.0	0.0	129.288651
3241	China	2020-04-09	1.0	3.0	124.034576
3242	China	2020-04-10	1.0	3.0	119.569534
3243	China	2020-04-11	1.0	0.0	115.158989
3244	China	2020-04-12	1.0	3.0	110.206604

Figura 19 - Previsão do número de mortes para a China

Italy

	index	unique_id	ds	Naive	SeasonalNaive	autoARIMA
7560	7560	Italy	2020-04-08	135586.0	110574.0	139242.078125
7561	7561	Italy	2020-04-09	135586.0	115242.0	142644.906250
7562	7562	Italy	2020-04-10	135586.0	119827.0	146145.531250
7563	7563	Italy	2020-04-11	135586.0	124632.0	149649.703125
7564	7564	Italy	2020-04-12	135586.0	128948.0	153018.843750

Figura 20 - Previsão do número de casos para a Itália

Italy

	unique_id	ds	Naive	SeasonalNaive	autoARIMA
7560	Italy	2020-04-08	17127.0	13155.0	17599.400391
7561	Italy	2020-04-09	17127.0	13915.0	18133.279297
7562	Italy	2020-04-10	17127.0	14681.0	18564.935547
7563	Italy	2020-04-11	17127.0	15362.0	18924.957031
7564	Italy	2020-04-12	17127.0	15887.0	19252.552734

Figura 21 - Previsão do número de mortes para a Itália

Portugal

	index	unique_id	ds	Naive	SeasonalNaive	autoARIMA
12060	12060	Portugal	2020-04-08	12442.0	8251.0	12979.901367
12061	12061	Portugal	2020-04-09	12442.0	9034.0	13556.326172
12062	12062	Portugal	2020-04-10	12442.0	9886.0	14120.038086
12063	12063	Portugal	2020-04-11	12442.0	10524.0	14708.905273
12064	12064	Portugal	2020-04-12	12442.0	11278.0	15245.089844

Figura 22 - Previsão do número de casos para Portugal

Portugal

	unique_id	ds	Naive	SeasonalNaive	autoARIMA
12060	Portugal	2020-04-08	345.0	187.0	363.707764
12061	Portugal	2020-04-09	345.0	209.0	397.442017
12062	Portugal	2020-04-10	345.0	246.0	416.410919
12063	Portugal	2020-04-11	345.0	266.0	449.888550
12064	Portugal	2020-04-12	345.0	295.0	469.109589

Figura 23 - Previsão do número de mortes para Portugal

Com a interpretação dos dados resultantes das tabelas da China, da Itália e de Portugal conseguimos perceber que os 3 métodos de previsão demonstram valores diferentes. É também importante mencionar que o método Naive apresenta uma previsão pouco fiável, uma vez que o último dia de casos confirmados de COVID-19 não correspondem muitas vezes a uma previsão correta para períodos futuros.
Tal como se pode ver na tabela 19, a China, tal como vários países não estão a relatar todas as mortes causadas pelo COVID-19. Algumas das razões para tal podem estar relacionadas a:

- **Capacidade limitada de teste:** Em muitos países, a capacidade de testagem para COVID-19 pode ser

limitada, o que significa que nem todas as pessoas que morrem com sintomas de COVID-19 são testadas para confirmar a causa da morte;

- **Subnotificação:** Os países podem não estar a registar todas as mortes de COVID-19 por questões políticas ou administrativas. Por exemplo, algumas mortes que acontecem num país podem estar erradamente a ser registadas como causadas por outras doenças;
- **Falta de recursos:** Alguns países podem não apresentar os recursos necessários para a recolha, analise e relatação dos dados sobre o COVID-19, o que pode resultar em atrasos nas comunicações das mortes;
- **Diferenças nos sistemas de saúde:** Em alguns países, o sistema de saúde pode ser fragmentado o que pode dificultar a recolha de informações sobre as mortes causadas pelo vírus.

Dado isto, é importante ter em conta que a subnotificação (notificar de forma incompleta) de casos ou mortes de COVID-19 pode ter implicações graves para a saúde publica e para as estratégias de prevenção e controle de pandemia.

VIII. Conclusões

Com a final interpretação dos dataset, podemos retirar deste algumas conclusões. Primeiramente, os 10 países com mais casos confirmados apresentam ser a maioridade dos casos mundiais. De seguida , através da interpretação dos gráficos podemos perceber que o número de casos aparenta estar a descer em maior parte dos países. Podemos também concluir que maior parte das regiões do mundo foram afetadas pelo COVID-19, e é também importante ter em atenção que existe uma grande porção de casos que não foram tidos em conta, o que pode influenciar a análise da propagação do vírus.

REFERENCES

[1] "Risk perceptions of COVID-19 around the world https://www.tandfonline.com/doi/full/10.1080/13669877.2020.1758193 (acessed May. 02, 2023).

[2] "CoronaTracker: World-wide COVID-19 Outbreak Data Analysis and Prediction" https://web.archive.org/web/20210308135402id_/https://www.who.int/bulletin/online_first/20-255695.pdf (acessed May. 02, 2023).

[3] "Universal Health Coverage Partnership Annual report 2021- Health systems strengthening and health emergencies beyond COVID-19." https://apps.who.int/iris/bitstream/handle/10665/366738/9789240067158-eng.pdf?sequence=1 (acessed May. 01, 2023).

[4] https://pt.wikipedia.org/wiki/Impactos_da_pandemia_de_COVID-19